



REDES NEURONALES 2024

Clase 19 parte 1

Lunes 28 de octubre 2024

FAMAF, UNIVERSIDAD NACIONAL DE CÓRDOBA

INSTITUTO DE FÍSICA ENRIQUE GAVIOLA (UNC-CONICET)


REPASO

BACK-PROPAGATION EN RED FEED-FORWARD CON UNA CAPA OCULTA

Buscamos hacer inferencias sobre cierta función desconocida f

$$f : \mathbb{R}^N \rightarrow \mathbb{R}^m$$

dado un conjunto de datos etiquetados $\mathcal{L} = \{(\bar{\mathbf{x}}^k, \bar{\mathbf{y}}^k)\} \quad k = 1, 2, \dots, P$



A partir de la expresión del ECM en función de todas las componentes de los vectores \bar{w}_i y \bar{w}_j , vamos a aplicar el descenso por el gradiente de una forma muy específica.

$$E[\{\bar{w}\}] = \frac{1}{2} \sum_{\mu=1}^P \sum_{i=1}^M [\xi_i^\mu - \phi_i^\mu]^2$$

$$= \frac{1}{2} \sum_{\mu=1}^P \sum_{i=1}^M \left[\xi_i^\mu - g_2 \left(\sum_{j=1}^L w_{ij} g_1 \left(\sum_{k=1}^N w_{jk} \xi_k^\mu \right) \right) \right]^2$$

Primero corregimos los pesos sinápticos \bar{w}_i (mayúscula) entre la capa oculta y la capa de salida sin importarnos por los \bar{w}_j (minúscula).

$$w_{ij}^{\text{nuevo}} = w_{ij}^{\text{anterior}} + \Delta w_{ij}$$

donde:

$$\Delta w_{ij} = -\eta \frac{\partial E}{\partial w_{ij}}$$

$$= \eta \sum_{\mu=1}^P \cancel{\frac{\partial}{\partial}} \left[\xi_i^\mu - \phi_i^\mu \right] g'_2(h_i^\mu) v_j^\mu$$

$$= \eta \sum_{\mu=1}^P \delta_i^\mu v_j^\mu$$

con

$$\delta_i^\mu = g'_2(h_i^\mu) [\xi_i^\mu - \phi_i^\mu]$$

Una vez que hemos actualizado todos los parámetros sinápticos de la última capa, pasamos a hacer lo mismo con los parámetros que van de la entrada a la capa oculta, o sea, los \bar{w}_j minúsculos. Para eso calculamos estas componentes del gradiente:

$$\omega_{jk}^{\text{nuevo}} = \omega_{jk}^{\text{viejo}} + \Delta \omega_{jk}$$

donde

$$\Delta \omega_{jk} = - \eta \frac{\partial E}{\partial \omega_{jk}}$$




$$= \eta \sum_{\mu=1}^P [y_i^{\mu} - \theta_i^{\mu}] g'_2(h_i^{\mu}) w_{ij} g'_1(h_j^{\mu}) z_k^{\mu}$$

$$= \eta \sum_{\mu=1}^P \delta_i^{\mu} w_{ij} g'_1(h_j^{\mu}) z_k^{\mu}$$

$$= \eta \sum_{\mu=1}^P \delta_j^{\mu} z_k^{\mu}$$

con

$$\delta_j^{\mu} = g'_1(h_j^{\mu}) \sum_i w_{ij} \delta_i^{\mu}$$



¿Cuántos parámetros tenemos?

$$(N \times L) + (L \times M) = L \times (N + M)$$

Este método se llama *back-propagation* o retro-propagación. Noten que le mostramos el elemento M del conjunto de entrenamiento a la red, la información viaja hacia adelante, en dirección a la salida. Con los resultados de las M salidas calculamos el error. Con el error primero calculamos las correcciones a los pesos sinápticos \overline{w}_i entre la capa oculta y la capa de salida. Una vez actualizados estos parámetros sinápticos pasamos a corregir los pesos sinápticos \overline{w}_j entre la entrada y la capa oculta.

REPASO DE BACK PROPAGATION

Pseudo-código

- Presentamos $\bar{\mathbf{z}}^h$, calculamos primero $\bar{\mathbf{v}}^h$ y luego $\bar{\mathbf{o}}^h$.
- Con $\bar{\mathbf{o}}^h$ y $\bar{\mathbf{z}}^h$ calculamos $E(\{\bar{\mathbf{W}}\})$.
- Con $E(\{\bar{\mathbf{W}}\})$ calculamos los valores de las correcciones δ_i^h ($i=1,2, \dots, M$) y con ellos $E(\{\bar{\mathbf{W}}\})$ los pesos sinápticos $\bar{\mathbf{W}}$ que van de la capa oculta a la capa de salida

$$W_{ij}^{\text{nuevo}} = W_{ij}^{\text{viejo}} + \Delta W_{ij}$$

- Con los δ_i^h ($i=1,2,\dots,N$) calculamos los δ_j^h ($i= 1,2, \dots, M$ y $j=1,2,\dots,L$) y con ellos actualizamos los pesos sinápticos $\bar{\mathbf{w}}_j$, que van de la entrada a la capa oculta.

$$w_{ij}^{\text{nuevo}} = w_{ij}^{\text{viejo}} + \Delta w_{ij}$$

El algoritmo ÉPOCA

A. Sea $\mu = 1$

B. Mientras $(\mu \leq P)$ repetimos

1. Con $\bar{\mathbf{X}}^\mu$ calculamos $\bar{\mathbf{V}}^\mu$

2. Con $\bar{\mathbf{V}}^\mu$ calculamos $\bar{\mathbf{O}}^\mu$

3. Con $\bar{\mathbf{O}}^\mu$ y $\bar{\mathbf{J}}^\mu$ calculamos E

4. Con E calculamos $\bar{\mathcal{J}}_i^\mu$

5. Con $\bar{\mathcal{J}}_i^\mu$ calculamos los $\Delta \bar{\mathbf{W}}$ y los acumulamos

$$\Delta \bar{\mathbf{W}} = \Delta \bar{\mathbf{W}} + \Delta \bar{\mathbf{W}}^\mu$$

6. Con $\bar{\mathcal{J}}_i^\mu$ calculamos los $\bar{\mathcal{J}}_j$

7. Con $\bar{\mathcal{J}}_j$ actualizamos los $\Delta \bar{\mathbf{w}}$ y los acumulamos

$$\Delta \bar{\mathbf{w}} = \Delta \bar{\mathbf{w}} + \Delta \bar{\mathbf{w}}^\mu$$

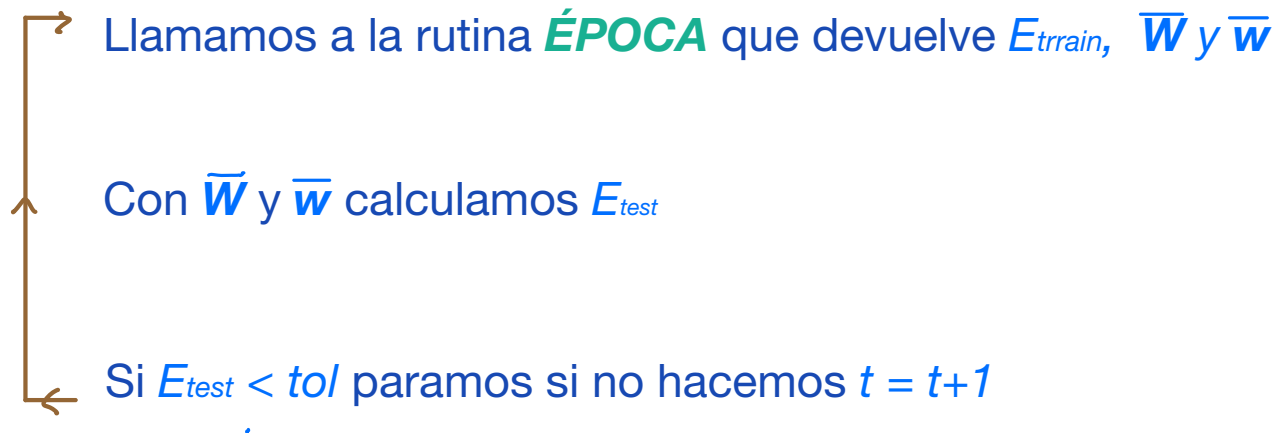
8. Pasamos al próximo ejemplo $\mu = \mu + 1$

9. Si $\mu = P$ actualizamos los $\bar{\mathbf{W}}_i$ y $\bar{\mathbf{w}}_j$ y volvemos a B

Leemos los datos:

- Conjunto de entrenamiento $(\bar{\mathbf{X}}, \bar{\mathbf{Y}})$
- Tolerancia tol
- Razón de aprendizaje η

Sea $t=1$



Hasta acá supusimos que actualizamos los acoplamientos sinápticos \bar{W} y \bar{w} después de mostrarle a la red todos los ejemplos del conjunto de entrenamiento, o sea después de una época. Esta forma de actualizar se conoce como *actualización en lote (batch)*.

$$\Delta W_{ij} = \Delta W_{ij}^{(1)} + \Delta W_{ij}^{(2)} + \dots + \Delta W_{ij}^{(p)}$$


$$\Delta w_{jk} = \Delta w_{jk}^{(1)} + \Delta w_{jk}^{(2)} + \dots + \Delta w_{jk}^{(p)}$$

Otra posibilidad que no hemos analizado es actualizar todos los pesos sinápticos \bar{W}_i y \bar{w}_j después de presentarle cada ejemplo del conjunto de entrenamiento a la red. Este método se denomina *actualización en línea (on line)*. Es una actualización más fina y precisa pero requiere mucho más cálculo numérico.

Veremos pronto que la forma más adecuada es una actualización en *mini-lotes (mini-batch)*, o sea, algo intermedio entre los métodos en lote y en línea.

EL MÉTODO BACK-PROPAGATION PARA UN NÚMERO ARBITRARIO DE CAPAS OCULTAS

Ahora podemos generalizar el método muy fácilmente para un número arbitrario de capas ocultas




Si queremos actualizar los acoplamientos \overline{w}_{pq} entre la capa q (anterior) y p (posterior)

$$\Delta \overline{w}_{pq}^{(q)} = \eta \sum_{p=1}^P \delta_p^H \overline{V}_q^{H(q)}$$

$$O_i = g(\sum w^{(4)} g(\sum w^{(3)} g(\sum w^{(2)} g(\sum w^{(1)} z))))$$

Caso1: cuatro neuronas en dos capas (una oculta)




$$V_1 = g(w_1 x)$$

$$V_2 = g(w_2 x)$$

$$O = g(W_1 V_1 + W_2 V_2)$$

$$= g(W_1 g(w_1 x) + W_2 g(w_2 x))$$

Caso 2: cuatro neuronas en tres capas (dos ocultas)



$$\begin{aligned} O &= g(w_3 \ V_2) = g(w_3 \ g(w_2 \ V_1)) \\ &= g(w_3 \ g(w_2 \ g(w_1 \xi))) \end{aligned}$$

